Contents

Rapport technique complet 1

Classification de Variants Génétiques : Prédiction de la Pathogénicité par Gradient Boosting 1
Table des matières . . . 1
1. Introduction et cadrage du problème . . . 2
2. Données sources et construction du label . . . 6
3. Sélection des variables . . . 8
4. Analyse de la variable cible . . . 8
5. Gestion des valeurs manquantes . . . 9
6. Feature Engineering . . . 10
7. Analyse statistique univariée . . . 12
8. Analyse statistique bivariée . . . 13
9. Diagnostic de multicolinéarité (VIF) . . . 15
10. Réduction de dimension (PCA) . . . 16
11. Détection des valeurs aberrantes . . . 17
12. Construction du dataset final . . . 18
13. Synthèse des décisions méthodologiques . . . 19
14. Modélisation — Phase 1 : Baselines . . . 19
15. Modélisation — Phase 2 : Ensembles & Gradient Boosting . . . 22
16. Interprétabilité — SHAP (SHapley Additive exPlanations) . . . 23
17. Évaluation finale sur le test set holdout . . . 25
18. Application exploratoire du modèle aux variants conflictuels . . . 27
PARTIE V — Prédiction de la conflictualité . . . 30
19. Prédiction des conflits de classification entre laboratoires . . . 30
20. Analyse comparative — Pathogénicité vs Conflictualité . . . 32
21. Conclusion . . . 33

Rapport technique complet

Classification de Variants Génétiques : Prédiction de la Pathogénicité par Gradient Boosting

Projet Machine Learning — M1 DTA/IA Auteur : Mahé BEGNIS, Remy RAYANE, Jibril BENSALEM
Date : 15 Avril 2026

Table des matières

I — Fondements et données

- **1.** Introduction et cadrage du problème — Biologie moléculaire (dont focus missense), scores de prédiction, conflits cliniques, pivot vers la pathogénicité, formalisation ML
- **2.** Données sources et construction du label — Jointure ClinVar, filtrage concordants P/LP + B/LB
- **3.** Sélection des variables — Critères d'exclusion (24 colonnes supprimées)
- **4.** Analyse de la variable cible — Ratio 4.08:1, conséquences sur les métriques

II — Prétraitement et analyse exploratoire

- **5.** Gestion des valeurs manquantes — MNAR identifié, stratégie de non-imputation pour GBM
- **6.** Feature Engineering — Encoding ordinal, log-AF, features dérivées
- **7.** Analyse statistique univariée — Position, dispersion, forme (skewness, kurtosis)
- **8.** Analyse statistique bivariée — Spearman, Mann-Whitney U, η^2
- **9.** Diagnostic de multicolinéarité (VIF) — CADD_RAW exclu (VIF=31)

- **10.** Réduction de dimension (PCA) — PC1=fréquence, PC2=pathogénicité
- **11.** Détection des valeurs aberrantes — Non supprimées (arbres invariants)
- **12.** Construction du dataset final — 22 features, split 80/20

III — Modélisation

- **13.** Synthèse des décisions méthodologiques
- **14.** Baselines (Phase 1) — LogReg, KNN, SVM : AUC = 0.9946
- **15.** Ensembles & Gradient Boosting (Phase 2) — RF, XGBoost, LightGBM, CatBoost : AUC = 0.9966
- **16.** Interprétabilité SHAP — CADD #1, directions biologiquement correctes

IV — Évaluation pathogénicité

- **17.** Évaluation finale sur test set holdout — AUC = 0.9962, DeLong, calibration
- **18.** Application exploratoire aux variants conflictuels — Distribution proba, cohérence consensus, SHAP critères

V — Prédiction de la conflictualité

- **19.** Conflictualité entre laboratoires — FE spécifique, AUC = 0.7949, SHAP, bug LightGBM
- **20.** Analyse comparative pathogénicité vs conflictualité — Features #1 différentes, deux problèmes distincts
- **21.** Conclusion — Double analyse, contributions, limites, perspectives

---

Répartition du travail :

I- Fondements et données : Mahé, Remy et Jibril

II- Prétaitement et analyse exploratoire : Remy et Jibril

III- Modélisation : Mahé

IV - Evaluation de la pathogénicité : Mahé, Remy et Jibril

V- Prédiction de la conflictualité : Mahé

---

1. Introduction et cadrage du problème

1.1 Du génome au variant : rappels de biologie moléculaire

L'ADN : support de l'information génétique L'acide désoxyribonucléique (ADN) est une macromolécule constituée de deux brins complémentaires enroulés en double hélice. Chaque brin est une séquence de **nucléotides**, dont l'unité d'information est la **base azotée** : adénine (A), thymine (T), cytosine (C) et guanine (G). Le génome humain contient environ **3,2 milliards** de paires de bases, réparties sur 23 paires de chromosomes (22 autosomes + 1 paire de chromosomes sexuels X/Y).

Des gènes aux protéines : le dogme central Un **gène** est un segment d'ADN qui contient l'information nécessaire à la synthèse d'une protéine. Le processus se déroule en deux étapes :

1. **Transcription** : l'ADN est copié en ARN messager (ARNm) dans le noyau cellulaire. Seules les régions **exoniques** du gène sont conservées dans l'ARNm mature (les **introns** sont excisés par épissage).
2. **Traduction** : l'ARNm est lu par les ribosomes dans le cytoplasme. Chaque triplet de bases (**codon**) code pour un **acide aminé** spécifique. La séquence d'acides aminés constitue la protéine, dont la fonction dépend de sa structure tridimensionnelle.

Le génome humain contient environ **20 000 gènes** codant pour des protéines, mais les régions codantes ne représentent que ~1,5% du génome total. Le reste inclut des régions régulatrices, des introns, et des séquences non codantes dont le rôle est encore partiellement compris.

Les variants génétiques : définition et types Un **variant génétique** (anciennement “mutation”) est une différence entre la séquence d’ADN d’un individu et la **séquence de référence** du génome humain (GRCh37/hg19 ou GRCh38/hg38). Chaque individu porte environ **4 à 5 millions** de variants par rapport à cette référence.

Les principaux types de variants :

Type	Mécanisme	Exemple	Impact typique
SNV (Single Nucleotide Variant)	Substitution d’une base	A → G en position 1 168 180 du chromosome 1	Dépend de la localisation
Délétion	Perte d’un ou plusieurs nucléotides	ATCG → A_CG	Peut décaler le cadre de lecture
Insertion	Ajout de nucléotides	ATCG → AT**GG**CG	Idem
Indel	Combinaison insertion + délétion	ATG → GC	Complexe

Conséquences moléculaires des variants La conséquence d’un variant dépend de sa **localisation** dans le gène :

Conséquence	Localisation	Effet sur la protéine	Sévérité typique
Missense	Exon (région codante)	Changement d’un acide aminé (ex: Glutamate → Aspartate)	**Variable** : peut être bénin ou pathogène (voir détail ci-dessous)
Nonsense	Exon	Crée un codon STOP prématuré → protéine tronquée	Généralement sévère (perte de fonction)
Synonymous	Exon	Le codon change mais code le même acide aminé (dégénérescence du code génétique)	Généralement bénin
Frameshift	Exon	Insertion/délétion dont la taille n’est pas un multiple de 3 → décalage du cadre de lecture → protéine totalement altérée en aval	Quasi toujours sévère
Intronic	Intron	Ne modifie pas directement la séquence protéique	Généralement bénin, sauf si site d’épissage affecté
Splice site	Jonction exon/intron	Altère le mécanisme d’épissage	Souvent sévère

Focus sur les variants missense — le cas le plus ambigu Le terme **missense** vient de l’anglais *mis-* (mauvais, erroné) + *sense* (sens, au sens du code génétique). Un variant missense change un seul nucléotide dans un codon, ce qui modifie l’acide aminé produit :

```
Code génétique (triplets → acides aminés) :
    ...  ATG   GAG   TTG   AAC  ...      ← séquence d'ADN
          ↓     ↓     ↓     ↓
    ...  Met   Glu   Leu   Asn  ...      ← séquence protéique

Variant missense (1 nucléotide change → 1 acide aminé change) :
    Normal  :  GAG → Glutamate (Glu, E)     acide aminé acide, chargé négatif
   Mutant  :  GAC → Aspartate (Asp, D)    acide aminé acide, chargé négatif  ← substitution conservatr
   Mutant  :  GCG → Alanine (Ala, A)     acide aminé hydrophobe, petit    ← substitution non conserva
```

Pourquoi le missense est le type le plus difficile à classifier :

Contrairement aux autres types de variants, l’impact d’un missense dépend de **trois facteurs simultanés** :

1. **La nature physicochimique de la substitution** : remplacer un Glutamate (acide, chargé) par un Aspartate (acide, chargé) est une substitution **conservatrice** — les propriétés chimiques sont similaires, la protéine tolère probablement le changement. En revanche, remplacer un Glutamate par une Proline (rigide, crée des coudes dans la chaîne) est une substitution **non conservatrice** et probablement délétère. C'est ce que mesure le score **BLOSUM62** de notre dataset.
2. **La position dans la protéine** : un changement dans le **site actif** d'une enzyme (où se produit la réaction chimique) est souvent catastrophique. Le même changement dans une **boucle flexible** en surface de la protéine peut être anodin. C'est ce que mesure **PolyPhen-2** (qui intègre la structure 3D).
3. **La conservation évolutive** : si la position est identique chez l'humain, la souris et le poisson zèbre depuis 450 millions d'années, c'est que toute mutation y est éliminée par la sélection naturelle → le changement est probablement délétère. C'est ce que mesurent **SIFT** et **CADD**.

Conséquence pour notre dataset : SIFT et PolyPhen ne sont définis **que** pour les variants missense (les seuls où le changement d'acide aminé est pertinent). C'est pourquoi ces features ont ~77% de NaN dans notre dataset — les variants non-missense (synonymous, frameshift, intronic, etc.) n'ont tout simplement pas de score SIFT/PolyPhen. Ce n'est pas une donnée manquante "accidentelle" mais un **MNAR structurel** (Missing Not At Random).

En résumé :

- **Nonsense/Frameshift** → quasi-toujours pathogène (facile à classifier, consensus entre labos)
- **Synonymous** → quasi-toujours bénin (facile)
- **Missense** → **ça dépend** (difficile, c'est là que les conflits surviennent et que les scores de prédiction sont utiles)

1.2 Conservation évolutive et scores de prédiction

Le principe de conservation Si une position du génome est **identique** chez l'humain, la souris, le poulet et le poisson zèbre (espèces séparées par ~450 millions d'années d'évolution), c'est que toute mutation à cette position a été **éliminée par la sélection naturelle** car elle était délétère. Inversement, une position qui varie entre espèces est sous faible contrainte évolutive et tolère les changements.

Ce principe fonde les scores de conservation (**CADD**, **GERP++**, **PhyloP**) utilisés dans notre dataset.

Scores de prédiction in silico

Score	Principe	Utilisation clinique
CADD (Combined Annotation Dependent Depletion)	Intègre >60 annotations (conservation, contexte séquence, régulation, etc.) en un score unique. La transformation Phred$= -10 \log_{10}(\text{rang}/n)$ permet une interprétation directe : CADD > 20 = top 1% des variants les plus délétères	Score de référence le plus utilisé en génomique clinique
SIFT (Sorting Intolerant From Tolerant)	Aligne la séquence protéique humaine avec ses homologues chez d'autres espèces. Si la position est conservée → substitution prédite délétère	Utilisé pour les variants missense uniquement
PolyPhen-2 (Polymorphism Phenotyping)	Combine conservation et structure 3D de la protéine pour prédire l'impact d'un missense	Idem, souvent utilisé en complément de SIFT
BLOSUM62	Matrice de substitution dérivée de l'alignement de séquences protéiques. Score négatif = substitution rare en évolution = probablement délétère	Mesure physicochimique de la "distance" entre acides aminés

Fréquence allélique et sélection naturelle La **fréquence allélique** (AF) est la proportion d'individus portant un variant dans une population de référence. Le raisonnement clinique est le suivant :

- Un variant **très fréquent** en population (AF > 5%) est quasi certainement **bénin** : un variant pathogène pour une maladie grave serait éliminé par la sélection naturelle avant d'atteindre une telle fréquence (règle BA1 des guidelines ACMG).
- Un variant **absent** des bases de données populationnelles (AF = 0) est **de signification incertaine** : il peut être pathogène (rare car délétère) ou simplement rare sans conséquence.

Trois bases de données populationnelles sont représentées dans notre dataset :

- **ESP** (Exome Sequencing Project) : ~6 500 exomes, populations européenne et afro-américaine
- **ExAC** (Exome Aggregation Consortium) : ~60 000 exomes, multi-ethnique
- **TGP** (1000 Genomes Project) : ~2 500 génomes complets, 26 populations

1.3 Le problème clinique : classifications conflictuelles

Le framework ACMG/AMP En 2015, l'American College of Medical Genetics (ACMG) et l'Association for Molecular Pathology (AMP) ont publié des guidelines standardisées pour la classification des variants (Richards et al., 2015, *Genetics in Medicine*). Chaque variant est classé en 5 catégories :

Catégorie	Abréviation	Signification	Action clinique
Pathogenic	P	Cause certaine de maladie (probabilité > 99%)	Diagnostic confirmé, conseil génétique
Likely Pathogenic	LP	Forte probabilité de causer la maladie (> 90%)	Traité comme pathogène en clinique
Variant of Uncertain Significance	VUS	Preuves insuffisantes	Pas d'action clinique directe, surveillance
Likely Benign	LB	Forte probabilité d'être bénin (> 90%)	Pas d'impact clinique
Benign	B	Certainement bénin (> 99%)	Pas d'impact clinique

La classification repose sur **28 critères** pondérés (8 critères de pathogénicité, 8 de bénignité, 12 combinatoires), incluant la fréquence allélique, les données fonctionnelles, la ségrégation familiale, les prédictions in silico, et la littérature scientifique.

Le problème des conflits Malgré la standardisation ACMG/AMP, **différents laboratoires peuvent classer le même variant différemment**. Les causes principales sont :

1. **Subjectivité résiduelle** : les guidelines laissent une marge d'interprétation (ex: le critère PM2 "absent des bases populationnelles" dépend du seuil de fréquence choisi)
2. **Accès inégal aux données** : tous les laboratoires n'ont pas accès aux mêmes bases de données internes
3. **Évolution temporelle** : un variant classé VUS en 2015 peut avoir été reclassé LP en 2023 grâce à de nouvelles publications, mais l'ancienne classification reste dans ClinVar
4. **Expertise variable** : les laboratoires ont des spécialisations différentes (cardio-génétique, oncogénétique, neurologie, etc.)

Une étude de Garber et al. (2016) a montré que ~15-20% des variants dans ClinVar ont des classifications discordantes entre laboratoires. Ces conflits ont un **impact clinique direct** : un patient dont le variant est classé "pathogène" par un labo et "VUS" par un autre peut recevoir un diagnostic erroné, un traitement inapproprié, ou une anxiété injustifiée.

Ce problème de conflictualité est ce qui motive la construction du dataset Kaggle utilisé dans ce projet (Kevin Arvai, "ClinVar Conflicting Classifications").

1.4 Pivotement de l'objectif : de la conflictualité à la pathogénicité

L'exploration initiale du dataset a révélé que la prédiction de la conflictualité est un problème **intrinsèquement difficile** : les scores de pathogénicité (CADD, SIFT, PolyPhen) ne sont pas discriminants pour la conflictualité

($\eta^2 < 0.001$), car un variant clairement pathogène ou clairement bénin est classé de manière **concordante** par tous les laboratoires — les conflits surviennent pour des raisons orthogonales à la sévérité biologique (manque de données populationnelles, subjectivité résiduelle des guidelines).

En revanche, en se concentrant sur les **variants concordants** (pour lesquels les laboratoires sont d'accord) et en récupérant leur classification clinique (Pathogenic/Likely Pathogenic vs. Benign/Likely Benign) via une jointure avec le fichier ClinVar variant_summary du NCBI, on obtient un problème de **prédiction de la pathogénicité** pour lequel les features génomiques sont hautement discriminantes (η^2 jusqu'à 0.57 pour CADD).

→ **L'objectif final du projet** : prédire si un variant génétique est **pathogène** ou **bénin**, à partir de ses caractéristiques génomiques, en utilisant uniquement les variants concordants entre laboratoires comme données d'entraînement fiables.

1.5 Formalisation mathématique

Type : Classification binaire supervisée.

Soit un variant v caractérisé par un vecteur de features $x_v \in \mathbb{R}^p$ (scores de conservation, fréquences alléliques, type de conséquence, etc.). On cherche :

$$f^* = \arg\min_{f \in \mathcal{F}} \mathbb{E}_{(X,Y)}[\mathcal{L}(Y, f(X))]$$

avec $Y \in \{0, 1\}$:

- $Y = 0$: Benign ou Likely Benign (concordant entre laboratoires)
- $Y = 1$: Pathogenic ou Likely Pathogenic (concordant entre laboratoires)

et $\mathcal{L}$ la fonction de perte (binary cross-entropy).

Stratégie de construction du label : on ne conserve que les variants pour lesquels les laboratoires sont **concordants** (pas de conflit de classification dans ClinVar), avec un label clair P/LP ou B/LB. Les variants conflictuels et les VUS sont exclus de l'entraînement — ils pourront être prédits par le modèle final comme application clinique.

1.6 Sources des données

Deux sources de données sont croisées :

1. **ClinVar Conflicting Classifications** (Kevin Arvai, Kaggle)
   - 65 188 variants avec features génomiques pré-annotées (VEP)
   - Contient les scores CADD, SIFT, PolyPhen, BLOSUM62, fréquences alléliques
   - Licence CC0
2. **ClinVar variant_summary** (NCBI FTP)
   - 4 474 219 entrées GRCh37
   - Contient la colonne `ClinicalSignificance` (P, LP, VUS, LB, B) absente du dataset Kaggle
   - Jointure sur (chromosome, position, ref, alt)

- **Référence génomique** : GRCh37/hg19
- **Annotation** : Ensembl VEP (Variant Effect Predictor)

---

2. Données sources et construction du label

2.1 Chargement et jointure

Source	Taille	Contenu
Kaggle (features)	65 188 × 46	Scores, fréquences, annotations VEP
ClinVar variant_summary (GRCh37)	4 474 219 lignes	ClinicalSignificance

Jointure : sur la clé (chromosome, position, ref, alt). **62 597 / 65 188** variants matchés (96.0%).

2.2 Construction du label pathogène/bénin

Après jointure, les variants sont classés :

Catégorie	N	Traitement
Benign (concordant, B+LB)	27 220	→ PATHOGENIC = 0
Pathogenic (concordant, P+LP)	6 506	→ PATHOGENIC = 1
Conflicting	21 890	Exclu (classification ambiguë)
Other (VUS, not provided, etc.)	6 981	Exclu
Unmatched	2 591	Exclu (pas de jointure)

Après filtrage (concordants CLASS=0 avec label clair P/LP ou B/LB) :

Métrique	Valeur
Nombre de variants	**28 546**
Pathogène (P + LP)	**5 620 (19.7%)**
Bénin (B + LB)	**22 926 (80.3%)**
Ratio B/P	**4.08:1**
Nombre de colonnes (brut)	50 (46 originales + 4 jointure)

2.2 Description des 46 colonnes brutes

Les colonnes se répartissent en plusieurs catégories fonctionnelles :

Catégorie	Colonnes	Description
Identifiants génomiques	`CHROM`, `POS`, `REF`, `ALT`, `CLNHGVS`	Position et nature de la mutation
Fréquences alléliques	`AF_ESP`, `AF_EXAC`, `AF_TGP`	Fréquence du variant dans 3 bases de données populationnelles
Annotations ClinVar	`CLNDISDB`, `CLNDN`, `CLNVC`, `CLNVI`, `MC`, `ORIGIN`, `CLNSIGINCL`	Metadata clinique
Annotations VEP	`Consequence`, `IMPACT`, `SYMBOL`, `Feature`, `BIOTYPE`, `EXON`, `INTRON`, `Amino_acids`, `Codons`	Conséquence biologique prédite
Scores de prédiction	`SIFT`, `PolyPhen`, `CADD_PHRED`, `CADD_RAW`, `BLOSUM62`, `LoFtool`	Scores in silico de pathogénicité
Motifs	`MOTIF_NAME`, `MOTIF_POS`, `HIGH_INF_POS`, `MOTIF_SCORE_CHANGE`	Données de motifs régulateurs
Variable cible	`CLASS`	0 = concordant, 1 = conflictuel

3. Sélection des variables

3.1 Critères d'exclusion

24 colonnes ont été supprimées selon 3 critères :

Critère 1 — Taux de NaN > 95% (5 colonnes) :

Colonne	% NaN	Justification
`CLNDISDBINCL`	99.7%	Sous-champ d'inclusion, quasi-vide
`CLNDNINCL`	99.7%	Idem
`CLNSIGINCL`	99.7%	Idem
`SSR`	99.8%	Sample-level info, quasi-vide
`DISTANCE`	99.8%	Distance au gène le plus proche, quasi-vide
`MOTIF_NAME/POS/HIGH_INF_POS/MOTIF_SCORE_CHANGE`	≈100%	Données de motifs, pratiquement vides (2 sur 65 188)

Critère 2 — Identifiants / metadata non prédictifs (14 colonnes) :

`POS`, `REF`, `ALT`, `CLNDISDB`, `CLNDN`, `CLNHGVS`, `CLNVI`, `Allele`, `Codons`, `Feature`, `Feature_type`, `cDNA_position`, `CDS_position`, `Protein_position`

Justification : ces colonnes sont des identifiants (position génomique exacte, notation HGVS) ou des metadata cliniques (noms de maladies associées). Les inclure comme features reviendrait à du data leakage (le nom de la maladie est une conséquence de la classification, pas une cause).

Critère 3 — Qualité insuffisante (1 colonne) :

`BAM_EDIT` : 51% NaN, variable technique d'alignement sans lien biologique avec la conflictualité.

3.2 Résultat

22 colonnes conservées sur 46 initiales (taux de rétention : 47.8%).

---

4. Analyse de la variable cible

4.1 Distribution

Classe	Effectif	Proportion
0 — Bénin (B + LB)	**22 926**	**80.3%**
1 — Pathogène (P + LP)	**5 620**	**19.7%**

Ratio majoritaire / minoritaire : 4.08:1

4.2 Interprétation et conséquences

Le déséquilibre est **significatif** (~4:1 en faveur des bénins). Un classifieur naïf prédisant systématiquement la classe 0 atteindrait **80.3% d'accuracy**. Ce déséquilibre reflète la réalité biologique : la majorité des variants génétiques sont bénins — seule une minorité altère la fonction d'un gène critique.

Conséquences méthodologiques :

1. L'**accuracy seule est inadaptée** comme métrique principale

2. Métriques retenues : **AUC-ROC** (principale), **F1-score**, **MCC** (Matthews Correlation Coefficient), **sensibilité** (un faux négatif = variant pathogène manqué = erreur clinique grave)
3. Utilisation de `class_weight='balanced'` ($w_k = \frac{n}{2 \cdot n_k}$) pour les modèles linéaires et `scale_pos_weight` ($\frac{n_{negative}}{n_{positive}} \approx 4.08$) pour les GBM
4. **Stratification obligatoire** dans tous les splits (train/test et cross-validation)

---

5. Gestion des valeurs manquantes

5.1 Quantification

13 colonnes sur 22 présentent au moins 1 valeur manquante.

Variable	N manquants	% NaN	Catégorie
`INTRON`	23 433	82.1%	Structurel (NaN si variant exonique)
`SIFT`	22 007	77.1%	Score de prédiction
`PolyPhen`	22 001	77.1%	Score de prédiction
`BLOSUM62`	21 901	76.7%	Score de substitution
`Amino_acids`	5 691	19.9%	Acides aminés affectés
`EXON`	5 167	18.1%	Structurel (NaN si variant intronique)
`LoFtool`	2 218	7.8%	Score de tolérance
`CADD_PHRED`	293	1.0%	Score de conservation
`CADD_RAW`	293	1.0%	Score de conservation
`MC`	107	0.4%	Conséquence moléculaire
`STRAND`	5	0.0%	Brin d'ADN
`BIOTYPE`	5	0.0%	Type de gène
`SYMBOL`	5	0.0%	Nom du gène

Observation : les taux de NaN pour SIFT/PolyPhen/BLOSUM62 sont plus élevés (~77%) que dans le dataset complet (~62%). Cela s'explique par le filtrage : en ne gardant que les concordants P/LP et B/LB, on a enrichi le sous-ensemble en variants nonsense, frameshift et splice (qui sont quasi-toujours pathogènes concordants) — et ces types n'ont pas de score SIFT/PolyPhen.

5.2 Analyse du mécanisme de missingness

L'analyse du pattern de NaN de SIFT en fonction du type de conséquence révèle un mécanisme **MNAR** (Missing Not At Random) :

Type de conséquence	N	SIFT NaN
`missense_variant`	31 444	**23.7%**
`synonymous_variant`	17 668	**100.0%**
`intron_variant`	4 403	**100.0%**
`frameshift_variant`	1 774	**100.0%**
`stop_gained`	1 702	**100.0%**
`missense_variant&splice_region_variant`	964	**20.6%**

Conclusion : SIFT (et PolyPhen, BLOSUM62) sont NaN pour **tous les variants non-missense**. L'absence du score est une **propriété intrinsèque du variant**, pas un artefact. Le NaN est **informatif** : il indique que le variant n'est pas un missense.

5.3 Stratégie de traitement

Situation	Décision	Justification
GBM (XGBoost, LightGBM, CatBoost)	**NaN conservés**	Ces modèles gèrent nativement les NaN : chaque split envoie les NaN vers le fils qui minimise la loss. L'imputation effacerait le signal MNAR.
Modèles linéaires (LogReg, SVM, KNN)	Imputation médiane + indicateur binaire `has_SIFT`, `has_PolyPhen`	La médiane est robuste aux outliers. L'indicateur binaire capture le signal MNAR.
`INTRON` / `EXON`	Transformés en binaires `is_intronic`, `is_exonic`	Le NaN signifie "pas dans un exon/intron" → l'information est la présence/absence

---

6. Feature Engineering

6.1 Encoding des variables textuelles

SIFT — Encoding ordinal (ordre de sévérité croissante) :

Catégorie	Code	Justification biologique
`tolerated`	0	La substitution est tolérée par la protéine
`tolerated_low_confidence`	1	Tolérée, mais avec peu de séquences homologues
`deleterious_low_confidence`	2	Délétère probable, confiance faible
`deleterious`	3	La substitution affecte la fonction protéique

PolyPhen — Encoding ordinal :

Catégorie	Code
`benign`	0
`possibly_damaging`	1
`probably_damaging`	2
`unknown`	NaN (pas de place dans l'ordonnancement)

IMPACT — Encoding ordinal (sévérité biologique) :

Catégorie	Code	Signification
`MODIFIER`	0	Régions non codantes
`LOW`	1	Synonyme, UTR
`MODERATE`	2	Missense
`HIGH`	3	Perte de fonction (stop, frameshift)

6.2 Transformation des fréquences alléliques

Les fréquences alléliques (AF) ont une distribution **extrêmement skewed** à droite (skewness > 5, cf. section 7). La majorité des variants ont AF = 0 (jamais observés en population).

Transformation : $AF_{log} = \log_{10}(AF + \varepsilon)$ avec $\varepsilon = 10^{-8}$

Justification : la transformation logarithmique réduit le skewness et rend les différences entre variants rares (AF = 0.0001 vs. AF = 0.001) plus visibles. L'ε évite le $\log(0)$.

6.3 Features dérivées

Feature	Formule	Justification
`is_rare`	$\mathbb{1}(AF_{ESP} = 0 \wedge AF_{EXAC} = 0 \wedge AF_{TGP} = 0)$	Un variant absent des 3 bases populationnelles est probablement pathogène ou très rare → plus susceptible de conflits
`is_exonic`	$\mathbb{1}(\text{EXON} \neq \text{NaN})$	Localisation structurelle
`is_intronic`	$\mathbb{1}(\text{INTRON} \neq \text{NaN})$	Localisation structurelle
`has_SIFT`	$\mathbb{1}(\text{SIFT} \neq \text{NaN})$	Indicateur MNAR : proxy pour "est un missense"
`has_PolyPhen`	$\mathbb{1}(\text{PolyPhen} \neq \text{NaN})$	Idem
`CHROM_encoded`	Ordinal 1-22, X→23, Y→24	Permet l'utilisation du chromosome comme feature numérique
`Consequence_grouped`	Top 10 + "other"	Réduit la cardinalité de ~30 à 11 catégories

Résultat : `is_rare = 1` pour **22 869 variants (35.1%)** du dataset.

6.4 Observations sur les distributions des features créées

Distribution bimodale de SIFT_encoded : L'encoding révèle une distribution bimodale très marquée :

Catégorie	Effectif	%
0 (tolerated)	11 484	46.2%
1 (tolerated_low_confidence)	1 077	4.3%
2 (deleterious_low_confidence)	775	3.1%
3 (deleterious)	11 500	46.3%

Seulement 7.5% des variants missense tombent dans les catégories intermédiaires. SIFT produit en pratique une classification quasi-binaire, ce qui est un résultat connu (Ng & Henikoff, 2003). Conséquence : les arbres de décision feront un split unique entre {0,1} et {2,3}.

Consequence_grouped : la catégorie `missense_variant` domine (31 444, 48.2%), ce qui est cohérent avec la surreprésentation des missense dans les variants cliniquement ambigus. Les catégories minoritaires de `CLNVC` (Inversion n=17, Microsatellite n=5) seront difficilement exploitables par les modèles.

2 328 gènes uniques (SYMBOL) : haute cardinalité interdisant un one-hot encoding direct. `SYMBOL` ne sera pas utilisé comme feature mais pourra servir de variable de groupement pour un `GroupKFold` (éviter le leakage intra-gène) ou pour créer des features agrégées (`n_variants_per_gene`) en phase de modélisation.

---

7. Analyse statistique univariée

7.1 Indicateurs de position et de dispersion

Référence : cours Modélisation Statistiques, Chap. 1 — Sections 1.3.1 et 1.3.2

Variable	N valide	Moyenne ($\bar{x}$)	Médiane (Q_2)	Écart-type (s)	CV (%)	IQR
`AF_ESP`	65 188	0.0145	0.0000	0.0578	398.3%	0.0012
`AF_EXAC`	65 188	0.0145	0.0000	0.0595	410.9%	0.0012
`AF_TGP`	65 188	0.0153	0.0000	0.0595	390.0%	0.0016
`CADD_PHRED`	64 096	15.686	14.090	10.836	69.1%	16.959
`CADD_RAW`	64 096	2.554	1.643	2.962	116.0%	3.918
`BLOSUM62`	25 593	-0.402	-1.000	1.873	465.5%	3.000
`LoFtool`	60 975	0.345	0.157	0.361	104.7%	0.686
`SIFT_encoded`	24 836	1.495	1.000	1.450	97.0%	3.000
`PolyPhen_encoded`	24 792	0.766	0.000	0.887	115.8%	2.000
`IMPACT_encoded`	65 188	1.570	2.000	0.750	47.8%	1.000

Interprétation du CV (cf. cours : CV < 10% → homogène, 10-30% → modéré, >30% → forte hétérogénéité) :

- **Toutes les variables ont CV > 30%** → forte hétérogénéité, ce qui est attendu en génomique (les variants couvrent un spectre allant de très fréquents à ultra-rares, de bénins à très pathogènes).

7.2 Indicateurs de forme

Référence : cours Modélisation Statistiques, Chap. 1 — Section 1.3.3

Variable	Skewness (γ_1)	Kurtosis (γ_2)	Interprétation
`AF_ESP`	**+5.466**	**+32.061**	Très forte asymétrie à droite, leptokurtique (queues extrêmement lourdes). Majorité des variants à AF=0.
`AF_EXAC`	**+5.434**	**+31.330**	Idem. Les 3 AF ont des distributions quasi-identiques.
`AF_TGP`	**+5.329**	**+30.432**	Idem.
`CADD_PHRED`	+0.379	-0.399	Quasi-symétrique, légèrement platykurtique. Distribution la plus proche d'une normale.
`CADD_RAW`	+1.609	+5.949	Asymétrie modérée à droite, leptokurtique.
`BLOSUM62`	+0.119	**-1.232**	Symétrique,**platykurtique** (queues légères). Cohérent : BLOSUM62 est borné à [-3, +3].
`LoFtool`	+0.652	**-1.201**	Légère asymétrie à droite, platykurtique.
`SIFT_encoded`	+0.011	**-1.938**	Quasi-uniforme sur {0,1,2,3} (kurtosis très négatif = distribution plate).
`PolyPhen_encoded`	+0.474	**-1.562**	Idem, avec légère surreprésentation de 0 (benign).
`IMPACT_encoded`	-0.329	-0.224	Quasi-symétrique, mésokurtique.

7.3 Validation quantitative de la transformation logarithmique

Les features `AF_*_log` ajoutées au tableau permettent de mesurer l'impact de la transformation $\log_{10}(AF + 10^{-8})$:

Métrique	AF_ESP (brut)	AF_ESP_log	Facteur d'amélioration
Skewness	**+5.47**	**+0.39**	÷14
Kurtosis	**+32.06**	**-1.59**	Leptokurtique → platykurtique
CV	398%	49.7%	÷8

La transformation est validée : le skewness passe de "fortement asymétrique" (>2) à "quasi-symétrique" (<0.5). Cette amélioration est consistante pour les 3 AF.

Note méthodologique : le CV des variables ordinales (SIFT_encoded à 97%, PolyPhen_encoded à 116%) n'a **pas de sens statistique strict** — le CV est défini pour des variables quantitatives sur une échelle de rapport. Son calcul sur un encoding ordinal {0,1,2,3} est un abus formel, conservé pour la complétude du tableau uniquement.

Conclusions sur la forme :

1. Les **fréquences alléliques** sont dominées par les variants rares (AF=0) → la transformation log est justifiée
2. **CADD_PHRED** a la distribution la plus "bien comportée" → feature probablement la plus exploitable par les modèles linéaires
3. Les **variables ordinales encodées** (SIFT, PolyPhen) ont un kurtosis très négatif → distributions quasi-uniformes, pas de concentration autour d'une valeur centrale

---

8. Analyse statistique bivariée

8.1 Corrélation de Spearman

Référence : cours Modélisation Statistiques, Chap. 2

Choix de Spearman plutôt que Pearson : les distributions sont non normales (skewness > 5 pour les AF), et plusieurs variables sont ordinales (SIFT, PolyPhen, IMPACT). Spearman mesure l'association monotone sans supposer la normalité ni la linéarité.

Paires fortement corrélées ($|\rho| > 0.7$) identifiées :

Variable 1	Variable 2	ρ de Spearman	Interprétation
`AF_ESP`	`AF_EXAC`	**0.877**	Même concept (fréquence allélique), populations différentes
`AF_EXAC`	`AF_TGP`	**0.877**	Idem
`AF_ESP`	`AF_TGP`	**0.861**	Idem
`AF_EXAC`	`is_rare`	**-0.813**	Par construction : is_rare = 1 quand AF = 0
`CADD_PHRED`	`PolyPhen_encoded`	**0.765**	Les deux mesurent l'impact fonctionnel d'un missense
`CADD_RAW`	`PolyPhen_encoded`	**0.765**	Idem
`CADD_PHRED`	`SIFT_encoded`	**0.713**	Idem
`CADD_RAW`	`SIFT_encoded`	**0.713**	Idem
`CADD_PHRED`	`CADD_RAW`	**1.000**	Transformation monotone déterministe ($Phred = -10 \log_{10}(\text{rank}/n)$)

Note : les corrélations AF sont plus élevées sur ce sous-ensemble (0.877 vs. 0.834 sur le dataset complet). Cela s'explique par l'exclusion des variants conflictuels (qui sont souvent des cas limites avec des couvertures inégales entre bases). Les corrélations CADD × SIFT/PolyPhen (0.71-0.77) confirment que ces scores mesurent des aspects proches mais non identiques de la pathogénicité.

8.2 Tests de Mann-Whitney U

Test non paramétrique : H_0 = les distributions de la feature sont identiques pour CLASS=0 et CLASS=1.

Correction de Bonferroni : $\alpha_{adj} = 0.05/13 = 0.00385$

Variable	U	p-value	Significatif	η^2	r (rank-biserial)
`CADD_RAW`	4 564 402	< 2.2e-16	**OUI**	**0.5718**	**0.9256**
`CADD_PHRED`	4 571 772	< 2.2e-16	**OUI**	**0.5307**	**0.9255**
`PolyPhen_encoded`	1 320 048	< 2.2e-16	**OUI**	**0.4407**	**0.7236**
`IMPACT_encoded`	11 128 439	< 2.2e-16	**OUI**	**0.4186**	**0.8273**
`SIFT_encoded`	1 712 606	< 2.2e-16	**OUI**	**0.3454**	**0.6409**
`is_rare`	35 208 649	< 2.2e-16	**OUI**	**0.1453**	0.4535
`BLOSUM62`	6 445 241	8.16e-118	**OUI**	**0.0765**	-0.3421
`AF_TGP`	104 871 124	< 2.2e-16	**OUI**	0.0366	-0.6279
`has_SIFT`	51 453 142	3.02e-227	**OUI**	0.0363	0.2013
`AF_ESP`	101 633 566	< 2.2e-16	**OUI**	0.0347	-0.5776
`AF_EXAC`	104 224 123	< 2.2e-16	**OUI**	0.0324	-0.6088
`LoFtool`	66 358 984	3.08e-104	**OUI**	0.0215	-0.1730
`is_exonic`	63 062 496	2.31e-04	**OUI**	0.0005	-0.0188

8.3 Analyse des résultats — Contraste radical avec le problème de conflictualité

Les résultats sont **spectaculairement différents** de ceux obtenus sur le problème de conflictualité :

Classement par pouvoir discriminant (η^2 décroissant) :

1. **`CADD_RAW`** ($\eta^2 = 0.5718$, $r = 0.926$) — Le score CADD explique à lui seul **57% de la variance** de la pathogénicité. C'est un résultat attendu : CADD a été explicitement conçu pour prédire la pathogénicité en intégrant >60 annotations. Le rank-biserial $r = 0.926$ signifie que dans 96.3% des paires (variant pathogène, variant bénin), le variant pathogène a un CADD plus élevé.
2. **`CADD_PHRED`** ($\eta^2 = 0.5307$) — Quasi-identique à CADD_RAW (transformation monotone).
3. **`PolyPhen_encoded`** ($\eta^2 = 0.4407$) — PolyPhen explique 44% de la variance. Les variants pathogènes sont massivement prédits "probably_damaging".
4. **`IMPACT_encoded`** ($\eta^2 = 0.4186$) — Les variants HIGH impact (nonsense, frameshift, splice) sont quasi-toujours pathogènes.
5. **`SIFT_encoded`** ($\eta^2 = 0.3454$) — SIFT deleterious est fortement associé à la pathogénicité.
6. **`is_rare`** ($\eta^2 = 0.1453$) — La rareté est un marqueur de pathogénicité (sélection purificatrice).
7. **`BLOSUM62`** ($\eta^2 = 0.0765$) — Significatif, contrairement au problème de conflictualité.

Toutes les 13 features sont significatives (p < α_Bonferroni pour toutes). C'est la situation inverse du problème de conflictualité où seulement 8/13 étaient significatives avec des $\eta^2 < 3\%$.

Comparaison avec le problème de conflictualité :

Feature	η^2 (conflictualité)	η^2 (pathogénicité)	Facteur
CADD_PHRED	0.0014	**0.5307**	×**379**
SIFT_encoded	0.0000	**0.3454**	→ **∞** (non significatif → dominant)

Feature	η^2 (conflictualité)	η^2 (pathogénicité)	Facteur
PolyPhen_encoded	0.0000	**0.4407**	**→ ∞**
IMPACT_encoded	0.0041	**0.4186**	**×102**
is_rare	0.0226	**0.1453**	**×6.4**

→ Ce contraste valide notre hypothèse de la section précédente : les scores de pathogénicité prédisent la pathogénicité (tautologie construite), pas la conflictualité (problème orthogonal). Le changement d'objectif transforme radicalement la structure du problème.

8.4 Implications pour la modélisation

Avec des η^2 individuels allant jusqu'à 57%, ce problème est **beaucoup plus accessible** que la conflictualité :

1. Même un modèle **linéaire** (LogReg) avec CADD_PHRED seul devrait atteindre une AUC-ROC > 0.90
2. Les GBM pourront exploiter les **interactions** pour gagner les derniers % (ex: un missense avec CADD modéré mais AF=0 dans toutes les bases → pathogène)
3. L'objectif réaliste est une **AUC-ROC > 0.95**, comparable aux outils existants (REVEL, ClinPred)
4. Le défi sera la **calibration** : en contexte clinique, la probabilité prédite doit être fiable, pas seulement le ranking

---

9. Diagnostic de multicolinéarité (VIF)

Référence : cours Modélisation Statistiques, Chap. 8 — Section 8.3.2

Le VIF (Variance Inflation Factor) est défini par :

$$VIF(X_i) = \frac{1}{1 - R_i^2}$$

où R_i^2 est le coefficient de détermination obtenu en régressant X_i sur l'ensemble des autres variables explicatives.

Seuils : VIF > 5 → colinéarité préoccupante ; VIF > 10 → colinéarité sévère.

Calculé sur **4 637 lignes complètes** (tous les NaN exclus pour pouvoir calculer les régressions). Le nombre réduit (vs. 18 300 sur le dataset complet) s'explique par le taux plus élevé de NaN pour SIFT/PolyPhen/BLOSUM62 sur ce sous-ensemble.

Variable	R^2	VIF	Diagnostic
`CADD_RAW`	0.968	**31.35**	**SEVERE**
`CADD_PHRED`	0.962	**26.15**	**SEVERE**
`AF_ESP`	0.787	4.70	Limite
`AF_EXAC`	0.789	4.74	Limite
`AF_TGP`	0.732	3.74	OK
`PolyPhen_encoded`	0.624	2.66	OK
`SIFT_encoded`	0.589	2.44	OK
`is_rare`	0.180	1.22	OK
`BLOSUM62`	0.161	1.19	OK
`LoFtool`	0.119	1.14	OK
`IMPACT_encoded`	0.018	1.02	OK

Variable	R^2	VIF	Diagnostic
`is_exonic`	1.000	**∞**	**Colinéarité parfaite**

Décisions prises

1. **`CADD_RAW` supprimé** : VIF = 26.64, lié à `CADD_PHRED` par une transformation monotone ($Phred = -10 \log_{10}(rank/n)$). On conserve `CADD_PHRED` car il est directement interprétable (CADD > 20 = top 1% des variants les plus délétères).
2. **`is_exonic`** : VIF = ∞ car parfaitement colinéaire avec `has_SIFT` et `is_intronic` dans le sous-ensemble complet. En pratique, cette colinéarité ne pose pas de problème pour les modèles à base d'arbres (chaque split ne considère qu'une variable à la fois). Pour les modèles linéaires, on pourra supprimer `is_intronic` (complémentaire de `is_exonic`).
3. **Les 3 AF** (VIF ~ 4-5) : corrélées mais **non redondantes** (populations différentes : ESP = européens, ExAC = multi-ethnique, TGP = 1000 Genomes). On les conserve toutes pour les GBM, on pourra créer une `AF_mean` pour les modèles linéaires si nécessaire.

---

10. Réduction de dimension (PCA)

Référence : cours Machine Learning, Chapitre 2 — PCA

10.1 Paramètres

- **Standardisation** : `StandardScaler` appliqué (obligatoire car les features ont des échelles très différentes : AF □ [0, 0.5] vs. CADD_PHRED □ [0, 99])
- **Échantillons** : 4 637 (lignes complètes sur les 12 features numériques retenues)
- **Features** : 12

10.2 Variance expliquée

Composante	Variance expliquée (%)	Cumulée (%)
PC1	**30.13**	30.13
PC2	**22.07**	52.20
PC3	10.41	62.61
PC4	10.00	72.61
PC5	8.94	81.55
PC6	8.16	89.71
PC7	3.91	93.62
PC8	3.30	**96.92**
PC9	1.77	98.69
PC10	1.31	100.00

- **6 composantes** pour 90% de variance (sur 12 features)
- **8 composantes** pour 95% de variance

Interprétation : la variance est **assez répartie** entre les composantes (PC1 n'explique que 30%). Cela indique que les données n'ont pas de structure dominante unique — les features apportent des informations complémentaires. Ce n'est pas un cas où la PCA permettrait une réduction drastique (7-8 composantes sur 12 = réduction limitée).

10.3 Loadings (contributions aux axes)

Feature	PC1	PC2	Interprétation
`AF_ESP`	**+0.4615**	+0.3440	PC1 dominé par les fréquences alléliques
`AF_EXAC`	**+0.4565**	+0.3476	Idem
`AF_TGP`	**+0.4575**	+0.3331	Idem
`CADD_PHRED`	-0.3299	**+0.4332**	PC2 dominé par les scores de pathogénicité
`SIFT_encoded`	-0.3082	**+0.4430**	Idem
`PolyPhen_encoded`	-0.3111	**+0.4280**	Idem
`BLOSUM62`	+0.1738	-0.2834	Contribution modérée
`LoFtool`	+0.1036	-0.0450	Faible contribution
`is_rare`	-0.1666	+0.0196	Faible contribution
`IMPACT_encoded`	-0.0044	+0.0042	Quasi nul

Interprétation structurelle :

- **PC1** = axe "fréquence en population" (AF élevé → PC1 positif)
- **PC2** = axe "pathogénicité prédite" (CADD élevé, SIFT deleterious, PolyPhen damaging → PC2 positif)

Ces deux axes sont **orthogonaux** (par construction), confirmant que fréquence populationnelle et pathogénicité prédite sont des dimensions indépendantes de la caractérisation d'un variant.

10.4 Features à loadings quasi-nuls

`IMPACT_encoded` (0.004), `is_exonic` (~0) et `has_SIFT` (~0) ne contribuent pas aux composantes principales. Explication : la PCA est calculée sur 18 300 lignes complètes, qui correspondent quasi-exclusivement aux **variants missense** (les seuls à avoir SIFT, PolyPhen et BLOSUM62 non-NaN). Dans ce sous-ensemble, `is_exonic`=1 et `has_SIFT`=1 pour **tous** les échantillons → variance nulle → loading nul.

10.5 Limitation majeure de l'analyse PCA

La PCA porte sur **4 637 / 28 546 = 16%** du dataset (lignes sans NaN). Les 72% restants (variants non-missense) sont exclus. Les conclusions structurelles ne sont donc valides que pour les variants missense avec scores complets. La PCA ne sera **pas utilisée pour la modélisation** (perte d'interprétabilité, incompatibilité avec les NaN natifs des GBM) mais uniquement pour la compréhension structurelle.

10.6 Visualisation 2D

La projection PC1-PC2 devrait montrer une **meilleure séparation** que dans le problème de conflictualité, étant donné les η^2 élevés (CADD à 0.53, IMPACT à 0.42). Les variants pathogènes devraient se concentrer dans la zone PC1 faible (rares) / PC2 élevé (CADD et scores de pathogénicité élevés), tandis que les bénins occupent la zone PC1 élevé (fréquents) / PC2 faible.

---

11. Détection des valeurs aberrantes

Référence : cours Modélisation Statistiques, Chap. 6 — Section 6.2

11.1 Méthode IQR

Valeurs aberrantes = observations hors de $[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$

Variable	Borne inf	Borne sup	N outliers	%
`CADD_PHRED`	-20.800	48.000	122	0.4%
`CADD_RAW`	-3.901	7.117	2 308	8.2%
`AF_EXAC_log`	-16.840	6.733	0	0.0%
`BLOSUM62`	-6.500	5.500	0	0.0%
`LoFtool`	-0.899	1.564	0	0.0%

Note : l'analyse des outliers porte sur `AF_EXAC_log` (log-transformé) et non `AF_EXAC` brut. Sur les AF brutes, la méthode IQR détecterait ~18% d'outliers — un artefact de la distribution zero-inflated (majorité à AF=0 → IQR minuscule → tout AF > 0.003 est flaggé). L'analyse sur les AF log-transformées est plus pertinente et ne détecte aucun outlier.

11.2 Décision : non-suppression des outliers

Les outliers ne sont PAS supprimés. Justification en 3 points :

1. **Invariance des modèles à base d'arbres** : XGBoost, LightGBM, CatBoost sont invariants aux transformations monotones. Les splits ne dépendent que de l'**ordre** des valeurs, pas de leur magnitude. Un CADD_PHRED de 99 sera simplement à droite de tous les splits, sans biais.
2. **Les "outliers" sont biologiquement valides** : un CADD_PHRED de 99 correspond à un variant dans une région **extrêmement conservée** du génome (top 0.1%). C'est une information cruciale, pas une erreur de mesure. De même, AF_EXAC = 0.05 n'est pas une aberration mais un variant polymorphe.
3. **Le 18.2% d'outliers pour AF_EXAC** est un artefact de la distribution : la majorité des variants ont AF=0, donc l'IQR est minuscule, et toute valeur > 0.003 est flaggée. Supprimer 18% du dataset biaiserait massivement l'échantillon.

Note : pour les modèles linéaires (LogReg, SVM), on utilisera un `RobustScaler` (basé sur la médiane et l'IQR) plutôt qu'un `StandardScaler` (basé sur la moyenne et l'écart-type, sensibles aux outliers).

---

12. Construction du dataset final

12.1 Vecteur de features

22 features réparties en 3 blocs :

Bloc	Features	N
Numériques	`AF_ESP`, `AF_EXAC`, `AF_TGP`, `AF_ESP_log`, `AF_EXAC_log`, `AF_TGP_log`, `CADD_PHRED`, `BLOSUM62`, `LoFtool`, `SIFT_encoded`, `PolyPhen_encoded`, `IMPACT_encoded`, `CHROM_encoded`, `STRAND`, `ORIGIN`	15
Binaires	`is_exonic`, `is_intronic`, `is_rare`, `has_SIFT`, `has_PolyPhen`	5
Catégorielles	`Consequence_grouped`, `CLNVC`	2

12.2 Split train / test

Ensemble	N	%	Bénin (0)	Pathogène (1)
Train	22 836	80%	18 340 (80.3%)	4 496 (19.7%)
Test	5 710	20%	4 586 (80.3%)	1 124 (19.7%)

La stratification est vérifiée : les proportions sont identiques dans train et test (80.3% / 19.7%).

Le test set ne sera touché **qu'une seule fois**, à l'évaluation finale.

---

13. Synthèse des décisions méthodologiques

Étape	Décision	Justification
Colonnes à >95% NaN	Supprimées	Aucune information exploitable
Identifiants cliniques	Supprimés	Prévention du data leakage
Mécanisme de missingness	MNAR identifié	SIFT=NaN □ non-missense (100% corrélé)
Imputation des NaN	**Non faite** (pour GBM)	Gestion native + signal MNAR informatif
Encoding SIFT/PolyPhen	Ordinal	Ordre de sévérité biologique préservé
Transformation AF	$\log_{10}(AF + 10^{-8})$	Réduction du skewness (>5 → ~0)
CADD_RAW	Supprimé	VIF = 26.64, redondant avec CADD_PHRED
Outliers	**Non supprimés**	Arbres invariants + valeurs biologiquement valides
Split	80/20 stratifié	Préserve la distribution 80.3/19.7
Métrique principale	AUC-ROC	Standard en classification binaire déséquilibrée
class_weight	`balanced` (LogReg, SVM)	$w_k = n/(2 \cdot n_k)$ — compense le ratio 4:1

Pipeline complet

```
DONNÉES
    Dataset Kaggle (65 188 × 46)
   + ClinVar variant_summary (4.5M lignes) → jointure (chr, pos, ref, alt) : 96% matchés
    → Filtrage concordants P/LP + B/LB → 28 546 variants, label PATHOGENIC (0/1)

PREPROCESSING
    → Suppression colonnes inutiles/NaN (→ 28 546 × 22)
   → Feature engineering (+13 dérivées) : log-AF, is_rare, SIFT/PolyPhen/IMPACT encoding
    → 22 features finales (15 num + 5 bin + 2 cat)
    → Split stratifié 80/20 → Train 22 836 | Test 5 710

MODELISATION (sur le train set uniquement)
    Phase 1 — Baselines : LogReg L1/L2, KNN, SVM → AUC = 0.9946 (LogReg L1)
    Phase 2 — GBM : RF, XGBoost, LightGBM, CatBoost → AUC = 0.9966 (XGBoost OOF)
    SHAP : interprétabilité (CADD #1, directions biologiquement correctes)

EVALUATION FINALE (test set, touché UNE SEULE FOIS)
    → XGBoost AUC = 0.9962, F1 = 0.9499, Brier = 0.0156
    → DeLong : GBM significativement > LogReg (p ≈ 0)
```

---

14. Modélisation — Phase 1 : Baselines

14.1 Protocole

Modèles : Logistic Regression L2, Logistic Regression L1 (Lasso), KNN (k=5, distance-weighted), SVM RBF.

Pipeline de preprocessing (obligatoire car ces modèles ne gèrent pas les NaN ni les catégorielles string) :

1. **Imputation médiane** des NaN numériques (robuste aux outliers, cf. cours Chap. 6)

2. **StandardScaler** ($z = \frac{x-\bar{x}}{s}$) — obligatoire pour KNN (distance euclidienne) et SVM (kernel RBF dont la valeur dépend de $\|x_i - x_j\|^2$)
3. **OneHotEncoder** pour `Consequence_grouped` et `CLNVC`
4. Le scaler est fit **uniquement sur le train fold** puis appliqué au validation fold (prévention du data leakage via `Pipeline`)

Évaluation : Stratified 5-Fold CV sur le train set (22 836). Le test set (5 710) n'est **pas touché**.

Gestion du déséquilibre :

- `class_weight='balanced'` pour LogReg et SVM : $w_k = \frac{n}{2 \cdot n_k}$ → les erreurs sur la classe minoritaire (pathogène) sont pondérées ×4.08
- KNN : pas de class_weight natif → le modèle optimise l'accuracy brute, biaisant vers la classe majoritaire

14.2 Résultats

Modèle	AUC-ROC	F1	MCC	Accuracy	Temps
LogReg L1	**0.9946 ± 0.0007**	0.9210 ± 0.0020	0.9021 ± 0.0024	96.73%	21.0s
LogReg L2	0.9944 ± 0.0006	0.9207 ± 0.0009	0.9018 ± 0.0010	96.72%	5.5s
SVM RBF	0.9933 ± 0.0005	**0.9302 ± 0.0046**	**0.9131 ± 0.0057**	**97.16%**	6.8s
KNN 5	0.9795 ± 0.0018	0.9302 ± 0.0035	0.9135 ± 0.0045	97.28%	2.8s

Rappel : classifieur naïf (toujours 0) → Accuracy = 80.3%, AUC = 0.50, F1 = 0.00, MCC = 0.00

Diagnostic d'overfitting :

Modèle	AUC train	AUC test	Gap	Verdict
LogReg L1	0.9948	0.9946	0.0002	Pas d'overfitting
LogReg L2	0.9946	0.9944	0.0002	Pas d'overfitting
SVM RBF	0.9949	0.9933	0.0016	Pas d'overfitting
KNN 5	**1.0000**	0.9795	**0.0205**	Overfitting léger (KNN mémorise le train)

14.3 Matrices de confusion (prédictions Out-Of-Fold)

Les prédictions OOF sont obtenues par `cross_val_predict` : chaque échantillon est prédit par un modèle entraîné sur les 4 autres folds → estimation honnête, non biaisée.

Modèle	Sensibilité (Recall P)	Spécificité (Recall B)	PPV (Précision P)	NPV (Précision B)	FN	FP
LogReg L1	**96.82%**	96.71%	87.82%	99.20%	143	604
LogReg L2	**96.80%**	96.70%	87.78%	99.19%	144	606
SVM RBF	95.95%	97.46%	90.25%	98.99%	182	466
KNN 5	92.08%	**98.56%**	**93.98%**	98.07%	**356**	265

Interprétation clinique :

- **LogReg L1/L2** : sensibilité maximale (96.8%) — seulement **143 variants pathogènes manqués** sur 4 496. Le `class_weight='balanced'` fonctionne efficacement : le modèle "préfère" surclasser un bénin (FP=604) plutôt que rater un pathogène. C'est le **profil cliniquement correct** : en diagnostic médical, un faux négatif (pathogène manqué) est bien plus grave qu'un faux positif (investigation supplémentaire).
- **KNN** : profil inverse — très spécifique (98.6%) mais **356 faux négatifs** (7.9% des pathogènes manqués). Sans `class_weight`, le KNN optimise l'accuracy globale et sacrifie la classe minoritaire. En clinique, ce taux de FN serait **inacceptable** pour un outil de diagnostic.
- **SVM RBF** : compromis intermédiaire — 182 FN, 466 FP. Le kernel RBF capture des non-linéarités qui améliorent le F1/MCC (meilleur seuil de décision) par rapport à LogReg, malgré un AUC légèrement inférieur.

Conclusion : LogReg L1 offre le meilleur AUC et la meilleure sensibilité. SVM offre le meilleur F1/MCC. Le choix dépend de la métrique prioritaire.

14.4 Feature selection par Lasso (LogReg L1)

La régression Lasso (L^1 : $\Omega(w) = \|w\|_1$, cf. cours Modélisation Stats Chap. 8) met à zéro les coefficients des features non informatives, réalisant une feature selection intégrée.

Résultat : 30 / 37 features retenues, 7 éliminées.

Top 10 features (par lcoefficient standardisél) :

Rang	Feature	Coefficient	Interprétation biologique
1	`AF_TGP`	**-9.606**	Plus le variant est fréquent en population → bénin (sélection purificatrice)
2	`AF_EXAC`	**-7.368**	Idem, population ExAC
3	`AF_ESP`	**-5.621**	Idem, population ESP
4	`Consequence_synonymous`	**-3.685**	Synonymous = pas de changement d'acide aminé → bénin
5	`Consequence_frameshift`	**+3.569**	Frameshift = protéine totalement altérée → pathogène
6	`CADD_PHRED`	**+1.853**	Score de conservation élevé → pathogène
7	`Consequence_missense`	**-1.553**	Missense = signal mixte (poids négatif car enrichi en bénins dans ce dataset concordant)
8	`Consequence_splice_region_intron`	**-1.525**	Région d'épissage intronique → majoritairement bénin
9	`IMPACT_encoded`	**+1.454**	Impact élevé → pathogène
10	`CLNVC_Duplication`	**-1.438**	Duplications → plutôt bénignes dans ce sous-ensemble

Features éliminées (coefficient = 0) :

- `Consequence_splice_acceptor_variant`, `Consequence_splice_donor_variant`, `Consequence_stop_gained` : éliminées non pas car non informatives, mais car **parfaitement capturées par IMPACT_encoded** (elles sont toutes HIGH impact). Le Lasso choisit IMPACT_encoded comme proxy et élimine les catégories redondantes.
- `CLNVC_Insertion`, `CLNVC_Inversion`, `CLNVC_Microsatellite`, `CLNVC_single_nucleotide_variant` : catégories trop rares (n ≤ 69) ou trop dominantes (97% SNV → variance quasi-nulle).

Observation critique : les AF brutes dominent le classement (positions 1-3) devant CADD (position 6). Cela ne signifie **pas** que l'AF est plus "importante" biologiquement que CADD — c'est un artefact du modèle linéaire : les AF brutes ont une échelle beaucoup plus large que CADD après standardisation, et leur effet est plus linéaire. Les GBM, qui ne sont pas affectés par l'échelle et capturent les non-linéarités, pourraient donner un classement différent (CADD en tête).

---

15. Modélisation — Phase 2 : Ensembles & Gradient Boosting

15.1 Protocole

Avantage des GBM : gestion native des NaN (le signal MNAR de SIFT/PolyPhen est préservé sans imputation) + capture des interactions non linéaires entre features.

Modèles :

- **Random Forest** (500 arbres, `max_features='sqrt'`, `class_weight='balanced'`) — utilise le même preprocessor que les baselines (RF ne gère pas les NaN)
- **XGBoost** (`lr=0.05`, `max_depth=6`, `scale_pos_weight=4.08`, early stopping 50 rounds)
- **LightGBM** (`lr=0.05`, `num_leaves=31`, leaf-wise, early stopping 50 rounds)
- **CatBoost** (`lr=0.05`, `depth=6`, `auto_class_weights='Balanced'`, ordered boosting, catégorielles natives)

Early stopping : `n_estimators=5000` (plafond) + arrêt automatique si pas d'amélioration sur le fold de validation pendant 50 itérations. Le nombre optimal d'itérations est déterminé automatiquement pour chaque fold.

Données :

- XGBoost/LightGBM : one-hot encoding des catégorielles, NaN conservés pour les numériques (37 features)
- CatBoost : catégorielles en string (encoding natif ordered target statistics), NaN conservés (22 features)
- Random Forest : même pipeline que les baselines (imputation médiane + StandardScaler + OneHot)

15.2 Résultats

Modèle	AUC-ROC	F1	MCC	Accuracy	Best iters (par fold)	Temps
XGBoost	**0.9966**	**0.9508**	**0.9387**	98.04%	[295, 421, 335, 208, 451]	4.8s
CatBoost	0.9965	0.9483	0.9356	97.93%	[510, 375, 435, 335, 441]	12.3s
LightGBM	0.9964	0.9504	0.9381	98.03%	[331, 369, 359, 378, 347]	13.1s
RandomForest	0.9957 ± 0.0004	0.9462	0.9330	97.88%	—	2.6s
LogReg L1 (ref)	*0.9946 ± 0.0007*	*0.9210*	*0.9021*	*96.73%*	—	*21.0s*

Diagnostic d'overfitting : gap train-test < 0.004 pour tous les modèles. Aucun overfitting.

Gain GBM vs baseline : XGBoost +0.0020 AUC, +0.030 F1, +0.037 MCC. Le gain est faible en AUC (la LogReg est déjà quasi-parfaite en discrimination) mais significatif en F1/MCC (les GBM améliorent la classification au seuil via les interactions non linéaires).

15.3 Matrices de confusion (OOF)

Modèle	Sensibilité	Spécificité	PPV	NPV	FN	FP
CatBoost	**96.53%**	98.27%	93.19%	**99.14%**	**156**	317
XGBoost	96.29%	98.47%	93.90%	99.08%	167	281
LightGBM	96.02%	98.52%	**94.07%**	99.02%	179	272
RandomForest	94.91%	98.60%	94.34%	98.75%	229	256

15.4 Analyse comparative

1. Les 3 GBM sont quasi-identiques (AUC 0.9964-0.9966). La différence est dans le 4e chiffre décimal — elle n'est probablement pas significative statistiquement (à vérifier par DeLong test lors de l'évaluation finale).

2. CatBoost : meilleure sensibilité (96.5%) et moins de FN (156). L'ordered boosting réduit le biais de target leakage, ce qui peut expliquer le léger avantage sur la détection de la classe minoritaire. C'est le profil le plus adapté au diagnostic clinique.

3. LightGBM : meilleure PPV (94.07%). Quand LightGBM prédit "pathogène", il a raison 94% du temps. C'est le profil le plus adapté si on veut minimiser les faux positifs.

4. Paradoxe LogReg vs GBM sur la sensibilité :

- LogReg L1 : sensibilité = 96.8%, FN = 143
- XGBoost : sensibilité = 96.3%, FN = 167
- CatBoost : sensibilité = 96.5%, FN = 156

LogReg a une sensibilité **légèrement supérieure** aux GBM. Explication : `class_weight='balanced'` dans LogReg pousse agressivement vers la détection de la classe minoritaire (le seuil de décision est décalé). Les GBM avec `scale_pos_weight` font un compromis plus équilibré sensibilité/spécificité. Ce trade-off pourra être ajusté via le **threshold tuning** post-entraînement.

5. Early stopping : XGBoost converge en 208-451 itérations, LightGBM en 331-378, CatBoost en 335-510. Aucun n'a eu besoin des 5000 max → l'early stopping a correctement évité le sur-apprentissage.

---

16. Interprétabilité — SHAP (SHapley Additive exPlanations)

16.1 Fondement théorique

SHAP (Lundberg & Lee, 2017) repose sur les **valeurs de Shapley** de la théorie des jeux coopératifs (Shapley, 1953). Pour chaque prédiction $f(x)$, la valeur de Shapley ϕ_j de la feature j vérifie :

$$f(x) = \mathbb{E}[f(X)] + \sum_{j=1}^{p} \phi_j(x)$$

C'est la **seule** décomposition satisfaisant simultanément les 4 axiomes : efficacité ($\sum \phi_j = f(x) - E[f]$), symétrie, nullité et additivité. Chaque ϕ_j a un signe (pousse vers pathogène ou bénin) et une magnitude (force de l'effet).

TreeSHAP (Lundberg et al., 2020) calcule ces valeurs **exactement** pour les modèles à base d'arbres en $O(TLD^2)$, sans approximation.

16.2 Protocole

- Modèle interprété : **XGBoost** (AUC = 0.9966, meilleur modèle global)
- Entraîné sur tout le train set (22 836 échantillons) avec `n_estimators=400` (moyenne des best iterations des 5 folds)
- SHAP calculé sur les 22 836 échantillons d'entraînement

16.3 Importance globale (Mean |SHAP|)

Rang	Feature	Mean	SHAP	
1	**CADD_PHRED**	**2.2702**	6e	Score intégratif de conservation — la feature dominante du GBM

Rang	Feature	Mean	SHAP	
2	AF_TGP	1.4944	1er	Fréquence en population → variant fréquent = bénin
3	IMPACT_encoded	0.8970	9e	HIGH impact (nonsense/frameshift) = pathogène quasi-certain
4	AF_EXAC	0.8226	2e	Fréquence en population (ExAC)
5	Consequence_synonymous	0.7971	4e	Pas de changement d'acide aminé → bénin
6	LoFtool	0.6662	hors top 10	Tolérance du gène à la perte de fonction
7	AF_ESP	0.5371	3e	Fréquence en population (ESP)
8	CHROM_encoded	0.3911	hors top 10	Effet chromosomique (certains chr enrichis en gènes critiques)

Contraste LogReg L1 vs SHAP : en LogReg, les AF brutes dominaient (coefficients -9.6 à -5.6) car leur effet est linéaire et leur échelle grande. En SHAP/GBM, **CADD reprend la 1re place** (2.27 vs 1.49 pour AF_TGP) car le GBM exploite les non-linéarités de CADD (seuils de décision autour de CADD ~15-20) que le modèle linéaire ne capture pas.

LoFtool en 6e position : cette feature n'apparaissait pas dans le top 10 du Lasso mais est importante pour le GBM. LoFtool mesure la tolérance d'un gène aux pertes de fonction — un gène critique (LoFtool bas) augmente la probabilité qu'un variant soit pathogène. C'est une **interaction gène-variant** que le modèle linéaire ne peut pas modéliser.

16.4 Beeswarm — Directions et non-linéarités

Le beeswarm plot montre, pour chaque feature, la distribution des SHAP values (axe horizontal) colorée par la valeur de la feature (rouge = élevée, bleu = basse). Les directions observées sont **toutes biologiquement correctes** :

Feature	Valeur haute (rouge) →	Valeur basse (bleu) →	Cohérence
CADD_PHRED	SHAP positif (→ pathogène)	SHAP négatif (→ bénin)	OK Conservation élevée = délétère
AF_TGP/EXAC/ESP	SHAP négatif (→ bénin)	SHAP positif (→ pathogène)	OK Fréquent = bénin (sélection purificatrice)
IMPACT_encoded	SHAP positif (→ pathogène)	SHAP négatif (→ bénin)	OK HIGH impact = perte de fonction
LoFtool	SHAP négatif (→ bénin)	SHAP positif (→ pathogène)	OK Gène tolérant = moins grave

Le modèle a redécouvert les mécanismes de la génétique sans qu'on les lui ait enseignés explicitement.

16.5 Dependence plots — Interactions apprises

Les dependence plots révèlent les **non-linéarités** et **interactions** :

- **CADD_PHRED** : effet quasi-linéaire pour CADD < 20, puis plateau pour CADD > 30 (saturation : au-delà de 30, le variant est déjà "certainement pathogène", plus besoin d'augmenter le score)
- **AF_TGP** : effet fortement non linéaire — pour AF > 0.01, le SHAP est massivement négatif (règle BA1 des guidelines ACMG : AF > 1% → bénin). Pour AF = 0, le SHAP est positif mais variable (dépend des autres features)

16.6 Waterfall — Explication d'un cas frontière

Le variant frontière (probabilité prédite = 0.498, label réel = bénin) illustre les forces en opposition :

- **CADD = 24.5** → pousse vers pathogène (+1.41) : la position est conservée
- **PolyPhen = benign** → pousse vers bénin (-0.80) : la substitution est tolérée structurellement
- **SIFT = tolerated** → pousse vers bénin (-0.58) : la substitution est tolérée évolutivement
- **LoFtool = 0.782** → pousse vers bénin (-1.16) : le gène tolère les pertes de fonction

Le modèle hésite parce que les signaux sont **contradictoires** — c'est exactement le profil d'un variant qui, en clinique, serait classé **VUS** (Variant of Uncertain Significance). La capacité du modèle à reproduire cette incertitude clinique est un signe de robustesse.

---

17. Évaluation finale sur le test set holdout

17.1 Protocole

Le test set (5 710 échantillons, 20%) n'a **jamais été touché** avant cette évaluation. Chaque modèle est ré-entraîné sur la **totalité** du train set (22 836), puis évalué une seule fois sur le test set.

- **Baselines + RF** : `n_estimators` fixé à la valeur d'entraînement initial
- **GBM** : `n_estimators` fixé à la moyenne des best iterations des 5 folds CV (XGBoost=400, LightGBM=360, CatBoost=430) — pas d'early stopping ici car pas de validation set

17.2 Résultats

Modèle	AUC-ROC	AUC-PR	F1	MCC	Sensibilité	Spécificité	PPV	Brier	FN	FP
XGBoost	**0.9962**	**0.9881**	0.9499	0.9375	96.09%	98.47%	93.91%	**0.0156**	44	70
CatBoost	0.9959	0.9869	0.9461	0.9328	96.09%	98.28%	93.18%	0.0173	44	79
LightGBM	0.9958	0.9869	**0.9523**	**0.9406**	96.00%	**98.63%**	**94.48%**	0.0158	45	63
RandomForest	0.9956	0.9862	0.9481	0.9354	95.11%	98.65%	94.52%	0.0168	55	62
LogReg L1	0.9933	0.9734	0.9177	0.8979	**96.26%**	96.69%	87.68%	0.0253	**42**	152
SVM RBF	0.9931	0.9774	0.9314	0.9147	96.09%	97.49%	90.38%	0.0186	44	115
LogReg L2	0.9931	0.9736	0.9177	0.8978	96.17%	96.71%	87.74%	0.0253	43	151
KNN 5	0.9793	0.9466	0.9198	0.9004	91.37%	98.21%	92.61%	0.0240	97	82

17.3 Cohérence cross-validation □ test set

Modèle	AUC-ROC (CV OOF)	AUC-ROC (Test)	Écart	Verdict
XGBoost	0.9966	0.9962	-0.0004	Cohérent
CatBoost	0.9965	0.9959	-0.0006	Cohérent
LightGBM	0.9964	0.9958	-0.0006	Cohérent
LogReg L1	0.9946	0.9933	-0.0013	Cohérent

Les écarts sont tous < 0.002 → les estimations CV étaient fiables. Pas de sur-apprentissage détecté.

17.4 Analyse des erreurs

XGBoost sur le test set :

- **44 faux négatifs** sur 1 124 pathogènes = 3.9% de pathogènes manqués
- **70 faux positifs** sur 4 586 bénins = 1.5% de bénins surclassés
- Ratio FN/FP = 0.63 → le modèle commet plus de FP que de FN, ce qui est le profil souhaité en diagnostic (mieux vaut sur-investiguer que manquer un pathogène)

LogReg L1 : meilleure sensibilité absolue (96.3%, 42 FN) mais **152 FP** (÷2 plus que XGBoost). Le `class_weight='balanced'` pousse agressivement vers la classe minoritaire, au détriment de la précision.

KNN : 97 FN (8.6% de pathogènes manqués) — cliniquement inacceptable, confirme l'analyse OOF.

17.5 Calibration

Modèle	Brier score	Interprétation
XGBoost	**0.0156**	Excellente calibration
LightGBM	0.0158	Excellente
RandomForest	0.0168	Très bonne
CatBoost	0.0173	Très bonne
SVM RBF	0.0186	Bonne
KNN 5	0.0240	Modérée
LogReg L1/L2	0.0253	Modérée

Le **Brier score** mesure l'erreur quadratique moyenne des probabilités : $BS = \frac{1}{n}\sum_{i=1}^{n}(\hat{p}_i - y_i)^2$. Un Brier de 0.0156 signifie que l'écart moyen entre la probabilité prédite et la réalité est de $\sqrt{0.0156} \approx 0.125$ (12.5 points de probabilité). C'est excellent.

Les GBM sont mieux calibrés que les baselines linéaires. Cela s'explique par le fait que les GBM modélisent les non-linéarités de la fonction de probabilité réelle, tandis que LogReg suppose une relation log-linéaire.

17.6 Test de DeLong — Significativité statistique

Comparaison	ΔAUC	Z	p-value	Significatif
XGBoost vs LogReg L1	+0.0029	291.1	< 0.0001	**OUI**
LightGBM vs LogReg L1	+0.0025	249.7	< 0.0001	**OUI**
CatBoost vs LogReg L1	+0.0026	261.8	< 0.0001	**OUI**
RandomForest vs LogReg L1	+0.0024	236.5	< 0.0001	**OUI**

Les 4 modèles ensemblistes/GBM sont **statistiquement significativement meilleurs** que la meilleure baseline (LogReg L1) en AUC-ROC. Le gain est faible en magnitude absolue (+0.0024 à +0.0029) mais extrêmement robuste statistiquement ($p \approx 0$).

17.7 Comparaison avec les outils de référence

Outil	Méthode	AUC-ROC (littérature)	Notre XGBoost
REVEL (Ioannidis et al., 2016)	Random Forest sur 13 scores	~0.96	**0.9962**

Outil	Méthode	AUC-ROC (littérature)	Notre XGBoost
ClinPred (Alirezaie et al., 2019)	GBM	~0.97	**0.9962**
M-CAP (Jagadeesh et al., 2016)	GBM	~0.95	**0.9962**

Notre modèle atteint des performances **comparables aux outils de référence** de la génomique clinique, malgré des conditions simplifiées (hyperparamètres par défaut, pas d'optimisation Optuna, features limitées aux annotations disponibles dans le dataset Kaggle).

Nuance importante : la comparaison directe n'est pas parfaitement fair car nos labels (ClinVar concordants) sont plus "propres" que ceux utilisés par REVEL/ClinPred (qui incluent des variants plus ambigus). Néanmoins, la performance est remarquable.

---

18. Application exploratoire du modèle aux variants conflictuels

18.1 Objectif et précautions méthodologiques

Le modèle de pathogénicité a été entraîné uniquement sur les **variants concordants** (cas faciles, AUC=0.9962). On souhaite **observer** comment il se comporte face aux **variants conflictuels** (CLASS=1, n=16 434), qu'il n'a jamais vus en entraînement. Cette analyse compense partiellement le **biais de sélection** documenté en section 20.3.

[!]□Limite épistémologique fondamentale : par définition, les variants conflictuels n'ont **PAS** de label de pathogénicité univoque — c'est ce qui les rend conflictuels. **Aucune mesure de performance prédictive classique** (AUC, F1) n'est rigoureusement applicable sur des données sans gold standard.

18.2 Stratégie en trois analyses complémentaires

On ne peut pas calculer une AUC sur les vrais conflits, mais on peut décomposer le problème en trois sous-questions, chacune avec sa rigueur propre :

Analyse	Population	Type	Question répondue
18.4 — Distribution des probabilités	16 434 (tous)	Descriptive (rigoureuse)	Comment le modèle se positionne-t-il ?
18.5 — Cohérence avec consensus	5 180 (label majoritaire)	Semi-rigoureuse	Le modèle reproduit-il le consensus quand il existe ?
18.6 — Critères du modèle (SHAP)	10 129 (vrais conflits)	Rigoureuse (no label)	Sur quels critères le modèle décide-t-il dans la zone grise ?

18.3 Catégorisation des variants conflictuels

Sur les 16 434 variants conflictuels, on identifie 3 sous-catégories via `ClinicalSignificance` du variant_summary NCBI :

Catégorie	N	%	Description
`pure_conflict`	**10 129**	61.6%	"Conflicting classifications of pathogenicity" — vrais conflits sans consensus
`benign_majority`	**4 294**	26.1%	Label B/LB malgré ≥1 dissident — consensus partiel
`pathogenic_majority`	**886**	5.4%	Label P/LP malgré ≥1 dissident — consensus partiel
`vus` / `unmatched` / `other`	1 125	6.9%	Exclus de l'analyse

18.4 Analyse 1 — Distribution des probabilités prédites

Application du modèle XGBoost (entraîné sur les concordants, AUC=0.9962) aux 16 434 variants conflictuels.

Statistiques descriptives :

Métrique	Valeur
Min	0.0000
Q1 (25%)	0.0010
Médiane	**0.0158**
Q3 (75%)	0.4013
Max	1.0000
Moyenne	~0.22
Std	~0.35

Répartition par zone :

Zone	Sens	N	%
[0.0, 0.1)	Très bénin	~10 200	~62%
[0.1, 0.4)	Plutôt bénin	~2 800	~17%
[0.4, 0.6)	**Zone grise**	~700	~4%
[0.6, 0.9)	Plutôt pathogène	~1 500	~9%
[0.9, 1.0]	Très pathogène	~1 200	~8%

Constat majeur : le modèle **ne reconnaît pas l'incertitude des conflits** — seulement 4% des prédictions tombent dans la zone grise [0.4-0.6]. Il tranche avec confiance, principalement vers le bénin (médiane = 0.016).

Interprétation biologique : c'est cohérent avec la composition réelle des conflictuels (~4 300 benign_majority + ~10 100 pure_conflict, dont beaucoup sont en réalité des variants à effet faible classés bénins par la majorité). Le modèle perçoit cette tendance.

18.5 Analyse 2 — Cohérence avec le consensus majoritaire

Précision méthodologique cruciale : sur les 5 180 variants où ClinVar a quand même attribué un label majoritaire (P/LP ou B/LB) malgré ≥1 dissident, on peut calculer une AUC. Mais cette AUC mesure la **cohérence** entre notre modèle et le consensus ClinVar, **PAS** la "performance sur les conflits". Le label vient de ClinVar, pas d'une vérité expérimentale.

Résultats sur les 5 180 variants à consensus majoritaire :

Métrique	Conflictuels (consensus)	Concordants (test)	Δ
AUC-ROC	**0.9779**	0.9962	-0.018
F1	**0.8332**	0.9499	-0.117
MCC	**0.7997**	0.9387	-0.139
Sensibilité	91.3% (809/886)	96.1%	-4.8 pts
Spécificité	94.3% (4047/4294)	98.5%	-4.2 pts
FN	77	44	+33
FP	247	70	+177

Interprétation :

1. **Δ AUC = -0.018 seulement** : le modèle reste très cohérent avec le consensus ClinVar, même en présence de dissidents
2. **Δ F1 = -0.117 et Δ MCC = -0.139** : la **classification au seuil 0.5** se dégrade plus que le ranking. Le modèle hiérarchise correctement mais le seuil est sous-optimal sur ces cas intermédiaires
3. **Asymétrie** : la sensibilité chute davantage que la spécificité — le modèle manque davantage les pathogènes ambigus (77 FN soit 8.7% des consensus_patho manqués)

Pourquoi cette dégradation est attendue : les variants à consensus majoritaire avec ≥1 dissident sont **structurellement intermédiaires** entre les concordants purs (consensus 100%) et les vrais conflits. La présence d'un dissident est elle-même un indicateur de complexité.

Borne supérieure : cette AUC de 0.9779 constitue la **borne supérieure** de la performance réelle sur les vrais conflits. La performance sur les `pure_conflict` (sans label) est probablement plus basse encore.

18.6 Analyse 3 — Critères du modèle sur les vrais conflits (SHAP)

C'est l'analyse **scientifiquement la plus pure** : pas de label, pas de mesure de performance, juste l'observation des **critères** que le modèle utilise pour trancher dans la zone grise.

Population : 10 129 variants `pure_conflict` (ClinVar = "Conflicting classifications" pure).

Distribution des prédictions sur ces 10 129 variants :

- Moyenne = **0.2227**
- Std = **0.3460** (forte dispersion)
- **Seulement 4.2% en zone grise [0.4-0.6]** — le modèle tranche presque toujours

Comparaison SHAP : pure_conflict vs concordants (training) :

Feature	SHAP pure_conflict	SHAP concordants	Δ
CADD_PHRED	**2.277**	2.270	**+0.007** (identique)
Consequence_synonymous	0.790	0.797	-0.008 (identique)
AF_TGP	**0.778**	1.494	**-0.716** (chute de 48%)
LoFtool	0.716	0.666	+0.049
AF_EXAC	**0.550**	0.823	**-0.273** (chute de 33%)
IMPACT_encoded	**0.522**	0.897	**-0.375** (chute de 42%)
CHROM_encoded	0.425	0.391	+0.034
PolyPhen_encoded	0.268	0.171	**+0.097** (hausse)
AF_ESP	0.244	0.537	-0.293

Résultats majeurs :

1. **CADD reste la feature #1 avec exactement le même poids** (2.277 vs 2.270, Δ = +0.007) → le modèle applique sa logique principale **de la même manière** sur les conflits que sur les concordants. C'est rassurant : il n'invente pas une nouvelle stratégie face à des données inconnues.
2. **Les fréquences alléliques perdent significativement de leur poids** : AF_TGP -48%, AF_EXAC -33%, AF_ESP -55%. Pourquoi ? Sur les vrais conflits, **les AF sont moins discriminantes** : beaucoup ont des AF intermédiaires (ni 0 ni > 1%), zone où la règle ACMG BA1 ("AF > 5% → bénin") ne tranche pas. Le modèle a appris que les AF extrêmes sont décisives → sur les valeurs intermédiaires des conflits, elles deviennent moins informatives.
3. **IMPACT chute de 42%** : les vrais conflits sont enrichis en MODERATE (missense ambigus) et appauvris en HIGH (qui sont quasi-toujours concordants pathogènes). La feature IMPACT discrimine moins bien dans cette population homogène.

4. **PolyPhen prend +57% de poids** : le modèle s'appuie davantage sur la prédiction structurelle 3D quand les autres critères sont moins discriminants — les scores fonctionnels prennent le relais des critères populationnels.

Interprétation scientifique majeure :

Le modèle **applique fondamentalement la même logique** sur les conflits que sur les concordants (CADD #1 inchangé). Ce qui change, c'est l'**importance relative** des features secondaires :

- **Concordants** : AF + IMPACT décisifs (cas extrêmes faciles à trancher)
- **Vrais conflits** : CADD + LoFtool + PolyPhen prennent le relais (cas intermédiaires nécessitant des critères plus fins)

C'est cohérent avec la nature biologique des conflits : ce sont les missense de la zone grise où les scores fonctionnels deviennent plus discriminants que les critères populationnels grossiers.

18.7 Synthèse — Que peut-on conclure rigoureusement ?

Cette analyse n'est **pas une validation prédictive** du modèle sur les conflits (impossible faute de gold standard). Elle apporte trois résultats distincts :

Conclusion	Niveau de rigueur	Limite
Le modèle**tranche avec confiance** sur les conflits (4% en zone grise)	Descriptive	Ne dit pas si c'est "correct"
Le modèle est**cohérent avec ClinVar** sur les consensus majoritaires (AUC=0.978)	Semi-rigoureuse	Mesure cohérence, pas prédiction
Le modèle**garde CADD comme critère #1** sur les vrais conflits, mais **transfère le poids** des AF vers PolyPhen/LoFtool	Rigoureuse (no label)	Descriptive uniquement

Limite fondamentale rappelée : aucune de ces 3 analyses ne peut affirmer "le modèle prédit correctement la pathogénicité des variants conflictuels" — cette affirmation est **épistémologiquement impossible** sans gold standard externe (ex: validation fonctionnelle expérimentale en laboratoire).

PARTIE V — Prédiction de la conflictualité

19. Prédiction des conflits de classification entre laboratoires

19.1 Objectif et intérêt clinique

Au-delà de la prédiction de la pathogénicité (problème résolu, AUC > 0.99), nous abordons un problème **non résolu dans la littérature** : prédire si un variant aura des classifications **contradictoires** entre laboratoires cliniques.

Intérêt clinique :

- Router proactivement les variants ambigus vers une revue inter-laboratoires **avant** que le conflit n'émerge
- Prioriser les efforts de curation de ClinVar (~milliers de soumissions/mois)
- Alerter les cliniciens : "ce variant a X% de chances d'être conflictuel → interpréter avec prudence"

Cible : `CLASS` □ {0=concordant (74.8%), 1=conflictuel (25.2%)}, ratio 2.97:1.

19.2 Feature engineering spécifique à la conflictualité

En plus des features de base (identiques à la pathogénicité), 4 features spécifiques ont été créées :

Feature	Formule	η^2	Justification
af_disagreement	$\sigma(AF_{ESP}, AF_{EXAC}, AF_{TGP})$	**0.0097**	Écart-type entre les 3 fréquences alléliques. Quand les bases populationnelles ne sont pas d'accord → incertitude → conflit.
cadd_ambiguity	$	CADD - 17.5	$
is_missense	$\mathbb{1}(\text{missense})$	0.0008	Les missense sont les variants les plus ambigus cliniquement.
n_submitters	Jointure variant_summary	0.0016	Plus de soumetteurs → plus de chances de désaccord (effet statistique).

19.3 Résultats — Analyse bivariée

Toutes les features ont un η^2 **très faible** (< 2.3%). Le classement par pouvoir discriminant :

Rang	Feature	η^2	Significatif (Bonferroni)
1	**is_rare**	**0.0226**	OUI
2	AF_TGP	0.0169	NON (p=0.013 > α_adj=0.003)
3	AF_ESP	0.0160	OUI
4	AF_EXAC	0.0147	OUI
5	**af_disagreement**	**0.0097**	OUI
6	IMPACT_encoded	0.0041	OUI
—	SIFT_encoded	0.0000	**NON**
—	PolyPhen_encoded	0.0000	**NON**
—	BLOSUM62	0.0000	**NON**
—	LoFtool	0.0000	**NON**

Confirmation : SIFT, PolyPhen, BLOSUM62, LoFtool sont **non significatifs** pour la conflictualité ($p > 0.05$ même sans correction de Bonferroni). La conflictualité est un problème d'**incertitude**, pas de **sévérité biologique**.

19.4 Résultats — Modélisation

Cross-validation (5-Fold stratifié, train set 52 150)

Modèle	AUC-ROC	F1	MCC	Gap train-test
XGBoost	**0.7883**	**0.5617**	**0.3869**	0.092
CatBoost	0.7871	0.5596	0.3835	0.057
RandomForest	0.7781	0.5018	0.3450	0.219 (attention)
LightGBM	0.7707	0.3497	0.2455	0.017
SVM RBF	0.7548	0.5293	0.3350	0.019
LogReg L1	0.7178	0.4944	0.2756	0.002
KNN 5	0.6851	0.3736	0.2129	0.315 (attention)

Bug LightGBM détecté et corrigé : la version initiale (lr=0.05, num_leaves=31) convergeait en 12 itérations vers un modèle trivial (F1=0.000, prédit toujours la classe majoritaire). Cause : la croissance leaf-wise avec un learning rate trop élevé atteint un plateau de logloss avant d'avoir appris le signal de la classe minoritaire. Correction : lr=0.01, num_leaves=63, min_child_samples=50. Résultat post-fix : F1=0.35, iters~70. LightGBM reste le plus faible des GBM sur ce problème.

Overfitting : Random Forest (gap=0.22) et KNN (gap=0.32) overfittent significativement. XGBoost (gap=0.09) a un overfitting modéré mais acceptable.

Évaluation finale — Test set holdout (13 038)

Modèle	AUC-ROC	F1	MCC	Sensibilité	Spécificité	Brier
XGBoost	**0.7949**	**0.5669**	**0.3949**	73.5%	71.1%	0.182
CatBoost	**0.7935**	**0.5669**	**0.3948**	74.1%	70.5%	0.185
RandomForest	0.7826	0.5004	0.3461	47.3%	86.0%	0.158
LightGBM	0.7787	0.5545	0.3755	73.3%	69.3%	0.191
SVM RBF	0.7592	0.5329	0.3409	75.0%	64.1%	0.160
LogReg L1	0.7215	0.5015	0.2883	77.3%	55.8%	0.217

Threshold tuning Le seuil optimal F1 est **0.52** (très proche du défaut 0.50), apportant un gain marginal (F1 = 0.5617 → 0.5620). Cela confirme que le seuil par défaut est quasi-optimal pour ce problème — le F1 modeste n'est pas un artefact du seuil mais reflète la **difficulté intrinsèque** du problème.

19.5 SHAP — Quelles features causent les conflits ?

Rang	Feature	MeanlSHAPl	Interprétation
1	**af_disagreement**	**0.3784**	Quand les bases de fréquences ne sont pas d'accord entre elles → conflit
2	AF_TGP	0.3072	Fréquence dans 1000 Genomes
3	**LoFtool**	**0.2509**	Tolérance du gène —**absent du top 10 en univarié** (η^2=0) mais capturé par le GBM via des interactions
4	AF_EXAC	0.2294	Fréquence dans ExAC
5	IMPACT_encoded	0.1310	Type d'impact biologique
6	**n_submitters**	**0.1271**	Plus de soumetteurs → plus de désaccord (effet purement statistique)
7	CHROM_encoded	0.1033	Effet chromosomique
8	AF_ESP	0.0904	Fréquence dans ESP
9	**CADD_PHRED**	**0.0784**	Relégué au 9e rang (était #1 pour la pathogénicité)
10	cadd_ambiguity	0.0689	Distance au seuil de décision

---

20. Analyse comparative — Pathogénicité vs Conflictualité

20.1 Performances comparées

Modèle	AUC Pathogénicité	AUC Conflictualité	Ratio
LogReg L1	0.9933	0.7215	1.38×
RandomForest	0.9956	0.7826	1.27×
XGBoost	**0.9962**	**0.7949**	**1.25**×
LightGBM	0.9958	0.7787	1.28×
CatBoost	0.9959	0.7935	1.26×

La pathogénicité est ~1.25× plus facile à prédire que la conflictualité. L'écart est massif : AUC 0.9962 vs 0.7949.

20.2 Features comparées (SHAP)

Rang	Pathogénicité	Conflictualité
1	**CADD_PHRED** (2.27)	**af_disagreement** (0.38)
2	AF_TGP (1.49)	AF_TGP (0.31)
3	IMPACT_encoded (0.90)	**LoFtool** (0.25)
4	AF_EXAC (0.82)	AF_EXAC (0.23)
5	Consequence_synonymous (0.80)	IMPACT_encoded (0.13)
6	LoFtool (0.67)	**n_submitters** (0.13)
9	—	CADD_PHRED (0.08)

Résultat majeur : les features qui prédisent la pathogénicité sont **fondamentalement différentes** de celles qui prédisent la conflictualité. CADD passe de la 1re à la 9e position. `af_disagreement` (absente en pathogénicité) devient #1 en conflictualité. Cela **démontre quantitativement** que pathogénicité et conflictualité sont deux problèmes distincts.

20.3 Interprétation biologique

- **Pathogénicité** = problème de **sévérité biologique**. Les variants pathogènes sont dans des régions conservées (CADD élevé), rares en population (AF basse), et altèrent la protéine (IMPACT HIGH). Les features sont conçues pour mesurer cette sévérité.
- **Conflictualité** = problème d'**incertitude épistémique**. Les conflits surviennent quand les données populationnelles sont contradictoires (af_disagreement), quand le variant est dans une zone de décision ambiguë (cadd_ambiguity), et quand de nombreux laboratoires avec des méthodologies différentes soumettent le même variant (n_submitters).

---

21. Conclusion

21.1 Résumé des résultats

Ce projet a développé et comparé **deux systèmes de prédiction** sur le même dataset ClinVar :

Problème	AUC-ROC (XGBoost)	F1	Intérêt
Pathogénicité (P/LP vs B/LB)	**0.9962**	0.9499	Reproduction de l'état de l'art (REVEL, ClinPred)
Conflictualité (concordant vs conflictuel)	**0.7949**	0.5669	**Problème original, non résolu dans la littérature**

21.2 Contributions méthodologiques

1. **Double analyse** sur le même dataset — comparaison inédite pathogénicité vs conflictualité
2. **Construction du label pathogénicité** par jointure ClinVar Kaggle × variant_summary NCBI (96% matching)
3. **Feature engineering spécifique** à la conflictualité : `af_disagreement`, `cadd_ambiguity`, `n_submitters`
4. **Analyse MNAR rigoureuse** des NaN (SIFT/PolyPhen absents pour les non-missense)
5. **8 modèles comparés** × 2 problèmes avec le même protocole (CV stratifié + holdout test set)
6. **SHAP comparatif** démontrant que pathogénicité ≠ conflictualité (features #1 différentes)
7. **Test de DeLong** confirmant la supériorité statistique des GBM sur les baselines
8. **Diagnostic et correction** du bug LightGBM (convergence triviale sur problème difficile)

21.3 Limites

Limite 1 — Biais de sélection du dataset (pathogénicité) Le dataset Kaggle (Kevin Arvai) est **pré-filtré** pour ne contenir que des variants soumis par au moins 2 laboratoires. Ce filtre, combiné à notre sélection des concordants P/LP et B/LB, introduit un **triple biais de sélection** dans le modèle de pathogénicité :

Biais 1 — Filtre "2+ soumetteurs" : les variants soumis par 1 seul laboratoire (79.6% de ClinVar) sont exclus. Ces variants sont souvent plus récents, moins étudiés, et potentiellement plus difficiles à classifier.

Biais 2 — Exclusion des conflictuels : les 16 434 variants conflictuels (CLASS=1) sont exclus de l'entraînement. Or ce sont précisément les **cas ambigus** — les missense à CADD moyen, AF modéré, où la classification est incertaine. Le modèle n'a jamais vu ces cas.

Biais 3 — Polarisation des distributions : le sous-ensemble concordant est enrichi en cas "extrêmes" :

- **9.0% de HIGH impact** dans les concordants (nonsense/frameshift = toujours pathogènes) vs **2.1%** dans les conflictuels
- **13.8% avec AF > 1%** dans les concordants (fréquent = toujours bénin) vs **2.7%** dans les conflictuels
- Les conflictuels sont concentrés dans le **milieu** (MODERATE 53.6%, LOW 35.3%)

Conséquence : l'AUC de 0.9962 mesure la capacité du modèle à séparer les variants **clairement** pathogènes des **clairement** bénins. En production, sur des variants ambigus (missense à CADD ~18, AF ~0.001), la performance serait probablement inférieure.

Mise en perspective : ce biais n'est **pas** une erreur méthodologique — c'est un choix contraint. On ne peut entraîner un classifieur supervisé que sur des labels fiables (concordants). Les outils de référence (REVEL, ClinPred, M-CAP) font exactement le même choix. L'analyse de conflictualité (sur les 65 188 variants complets) compense partiellement ce biais en exposant le modèle à la zone grise.

Limite 2 — F1 modeste pour la conflictualité F1 = 0.57 : modeste en absolu, mais cohérent avec la difficulté du problème (η^2 max = 2.3%). Le signal est intrinsèquement faible car la conflictualité dépend de facteurs non observables dans notre dataset (date de soumission, politique interne des laboratoires, accès à des données fonctionnelles non publiques).

Limite 3 — Features limitées Pas de scores GERP++/PhyloP, pas de pLI (probability of Loss-of-function Intolerance), pas de review_status ClinVar, pas d'identifiants des laboratoires soumetteurs.

Limite 4 — Pas d'optimisation Optuna Les hyperparamètres par défaut donnent déjà AUC > 0.99 (pathogénicité) et AUC ~0.79 (conflictualité). Le gain marginal attendu d'Optuna est faible, mais non testé.

Limite 5 — Pas de validation externe Le modèle n'a été évalué que sur un split du même dataset ClinVar. Une validation sur un dataset indépendant (ex: ClinVar 2027 vs modèle entraîné sur données 2026) ou sur un autre registre (ex: LOVD, HGMD) renforcerait la validité.

21.4 Perspectives

1. **Application clinique combinée** : un variant avec P(pathogène) > 0.8 ET P(conflictuel) > 0.6 = priorité maximale pour une revue inter-laboratoires
2. **Enrichissement des features** avec dbNSFP, review_status ClinVar, date de première soumission
3. **Validation temporelle** : entraîner sur ClinVar 2024, tester sur les nouveaux variants de 2025-2026
4. **Stacking** des deux modèles : les prédictions du modèle de pathogénicité comme feature pour le modèle de conflictualité